Подготовка данных для классификации писем

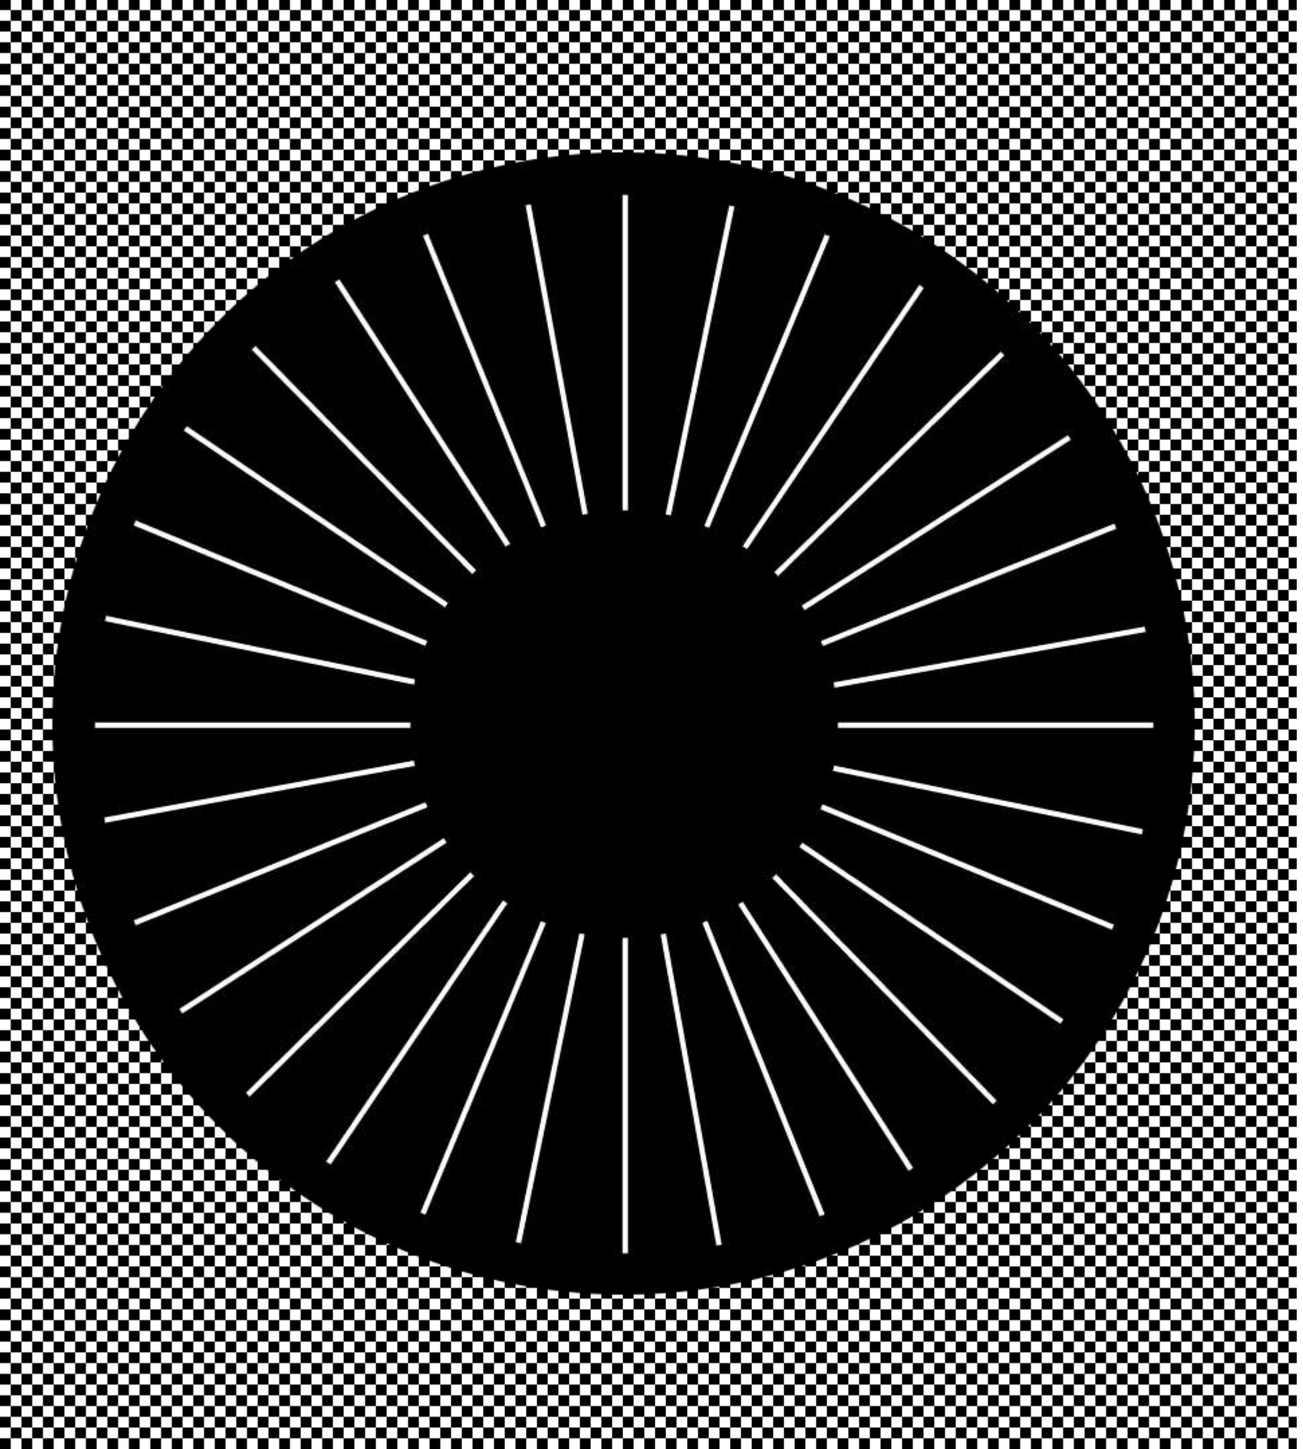

КОМАНДА GEORGE

КАПИТАН КОМАНДЫ

Витвицкий Роман

ЧЛЕНЫ КОМАНДЫ

Фатхутдинов Самир
Юзыкаев Равиль
Сапоговский Георгий
Коклев Тимофей

01
Постановка задачи

ДАННЫЕ

ФОРМАТ: JSON, СПИСОК СЛОВАРЕЙ С ПОЛЯМИ:

- IDX — ИДЕНТИФИКАТОР ПИСЬМА
- TEXT — ТЕКСТ ПИСЬМА
- LABEL — ЦЕЛЕВОЙ ОТДЕЛ ИЛИ ПРОЕКТ
- ОБЪЁМ TRAIN-ДАТАСЕТА: 1421 ПИСЬМО
- КОЛИЧЕСТВО КЛАССОВ: 36

МЕТРИКИ

MACRO F1 - СРЕДНЕЕ F1 ПО ВСЕМ 36 КЛАССАМ,

$$\mathrm{macroF1} = \frac{1}{36}\sum_{k=1}^{36} F1_k$$

ДИСПЕРСИЯ F1 ПО КЛАССАМ,

$$\mathrm{Var} = \frac{1}{36}\sum_{k=1}^{36}(F1_k - \mathrm{macroF1})^2$$

ИТОГОВЫЙ SCORE НА ЛИДЕРБОРДЕ,

$$\mathrm{Score} = \mathrm{macroF1} - 0{,}1 \cdot \sqrt{\mathrm{Var}}$$

02
EDA: дисбаланс классов

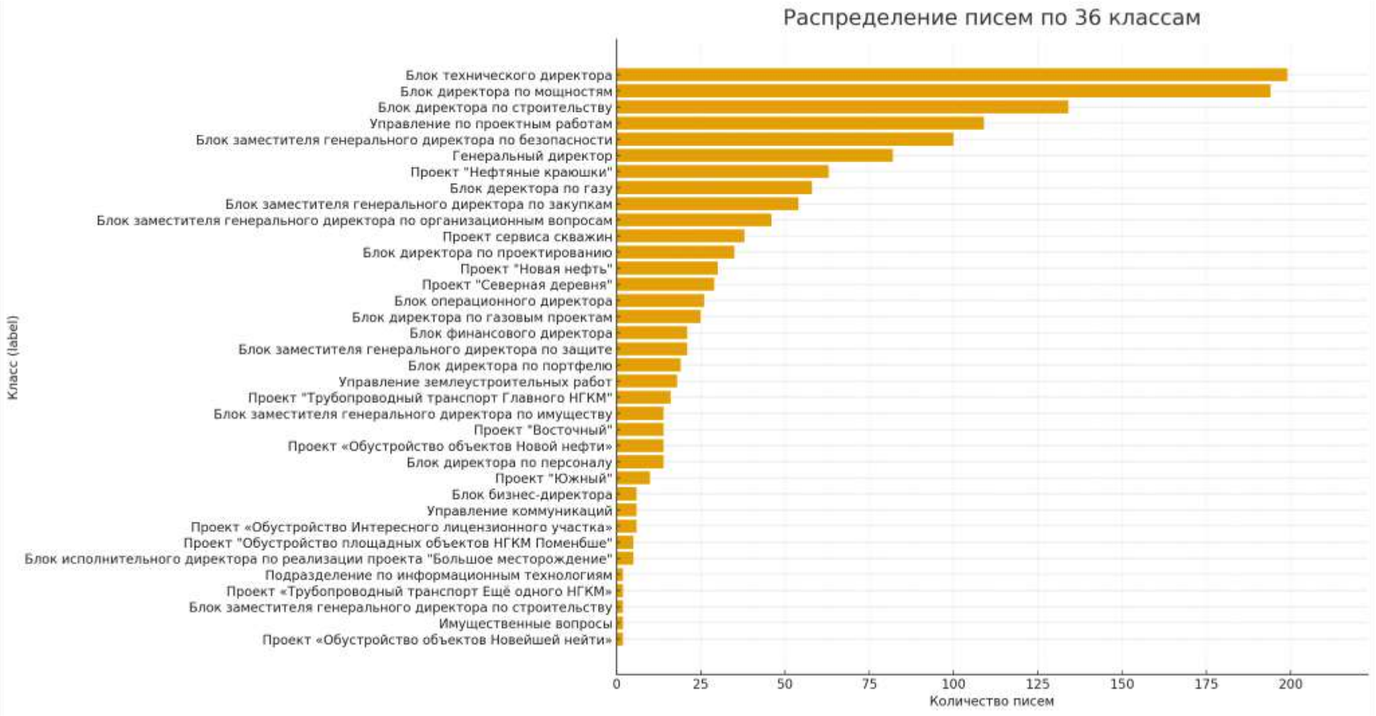

Сводка

Всего писем: 1421
Всего классов: 36
Минимум писем в классе: 2
Максимум писем в классе: 199
Разброс: от 2 до 199 (≈100× разница)

Большой дисбаланс

Топ-3 отделов покрывают примерно 37% датасета, топ-10 — уже 73%. Тем временем у топ-10 самых редких классов суммарно 38 писем, т.е. около 2,7%

Проблема

Из-за редкой встречаемости большого числа классов, модель может начать их “игнорировать”, из-за чего могут ухудшиться показатели Macro F1 и дисперсии.

03
EDA: длина писем

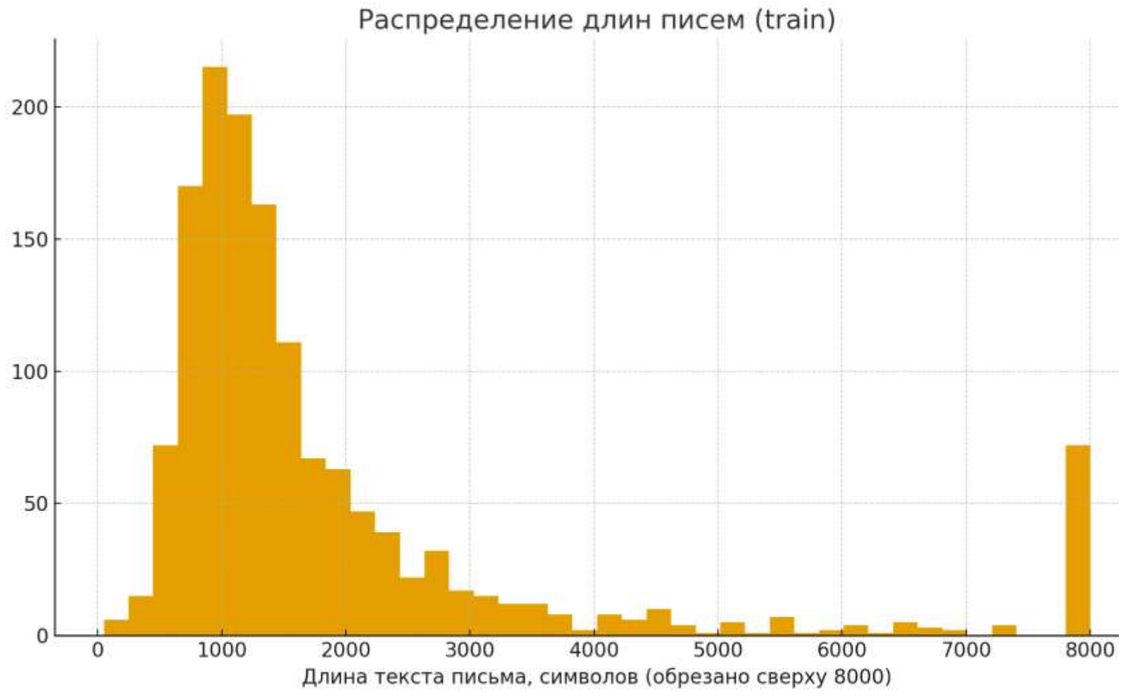

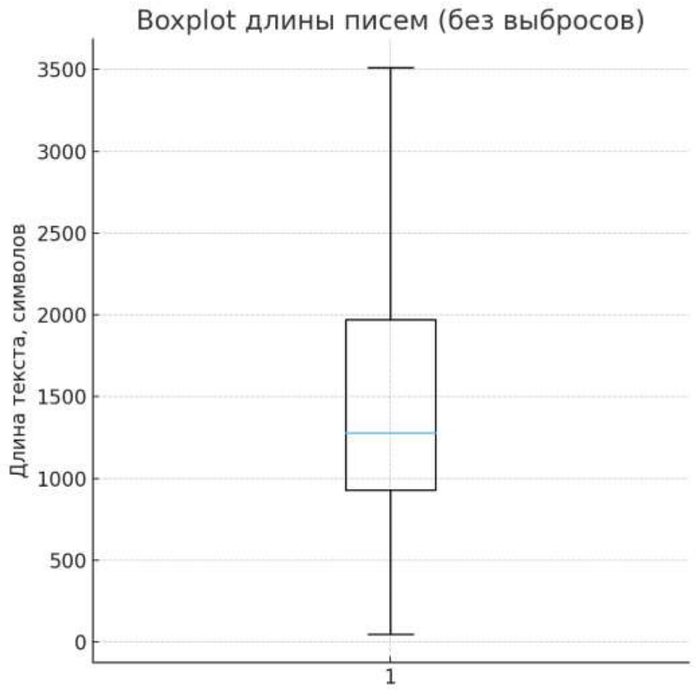

Сводка

Минимум: 49
25-й перцентиль: 931
Медиана: 1279
75-й перцентиль: 1972
Среднее: 3027
Максимум: 69 225

Дисбаланс длин писем

Основная масса писем — от ~500 до ~3000 символов, но есть длинный хвост. По Boxplot видно, что нормальные значения сосредоточены до ~3500 символов, а значения выше — редкие и сильно выбивающиеся.

Проблема

Слишком длинные письма могут вести к проблемам при обучении BERT: модель всё равно ограничена по длине входа, и часть текста будет отбрасываться.

05
Гипотезы

НАБЛЮДЕНИЯ ИЗ EDA

A

Сильный дисбаланс классов

- от 2 до 199 писем на класс;
- топ-10 классов ≈ 73% данных;
- хвост-10 классов — всего ≈2.7%.

B

Сильно различающиеся длины писем

- медиана ≈ 1279 символов;
- 75-й перцентиль ≈ 1972;
- максимум ≈ 69к символов.

C

Повторяющиеся технические хвосты

- блоки вида «ДОКУМЕНТ ПОДПИСАН ЭЛЕКТРОННОЙ ПОДПИСЬЮ…» встречаются в письмах разных классов.

D

Обезличенные сущности и формальный стиль

- [ORGANIZATION], [PERSON], [ID], …
- много типовых канцелярских оборотов.

ГИПОТЕЗЫ

A

БАЛАНСИРОВКА ХВОСТОВЫХ КЛАССОВ

Гипотеза: oversampling и догенерация редких классов улучшат macro F1 и снизят дисперсию.

B

ОЧИСТКА ТЕХНИЧЕСКОГО ШУМА

Гипотеза: удаление повторяющихся хвостов ЭЦП и нормализация форматирования упростят задачу для модели и улучшат качество.

C

ОБРЕЗКА СЛИШКОМ ДЛИННЫХ ПИСЕМ

Гипотеза: так как BERT ограничен по длине входа, обрезка текстов до разумного лимита (например, 4000–6000 символов).

D

РАБОТА С КАЧЕСТВОМ РАЗМЕТКИ

Гипотеза: в данных могут быть отдельные письма “не в свой класс”; аккуратная корректировка меток по сильной baseline-модели улучшит качество.

E

ГЕНЕРАЦИЯ ДАННЫХ

Гипотеза: генерация новых писем в стиле редких классов увеличит их разнообразие и поможет модели.

06
Агрессивный oversampling

ИДЕЯ V1

ЦЕЛЬ: ВЫРОВНЯТЬ КОЛИЧЕСТВО ПИСЕМ В КЛАССАХ, ЧТОБЫ МОДЕЛЬ НЕ “ЗАБЫВАЛА” ХВОСТ.

СХЕМА OVERSAMPLING’A:

- ЕСЛИ В КЛАССЕ N ≥ 40 — ОСТАВЛЯЕМ КАК ЕСТЬ;
- ЕСЛИ 20 ≤ N < 40 → ДУБЛИРУЕМ ОБЪЕКТЫ ДО 40;
- ЕСЛИ N < 20 → ДУБЛИРУЕМ ДО 30.

В ИТОГЕ КАЖДЫЙ КЛАСС ОТ 30-40 ПИСЕМ.

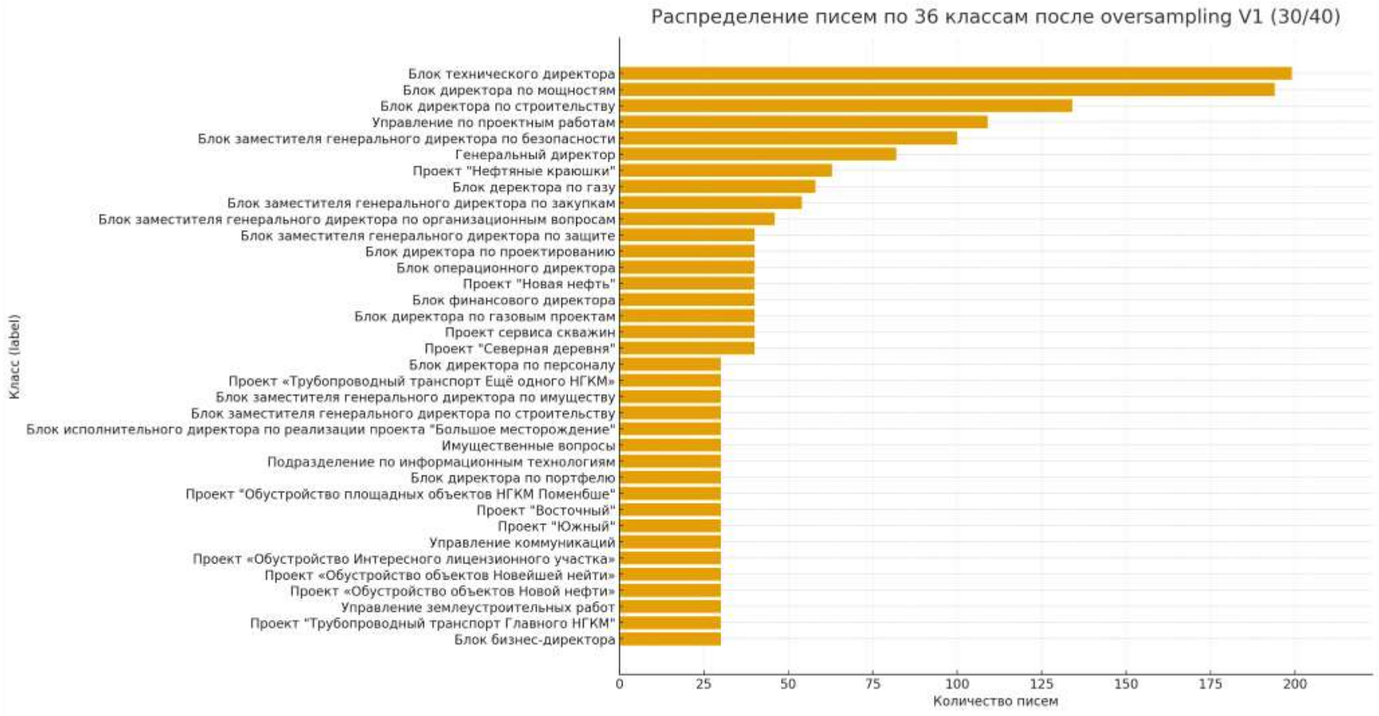

Сводка

1899 писем (рост ≈ +34%);
всё ещё 36 классов;
минимум: 30 писем на класс,
25-й перцентиль: 30,
медиана: 35,
75-й перцентиль: 48,
максимум: 199.

Изменение метрик

Score на тесте: 0.416869 vs 0.424846 (базовые)
Macro F1: 0.446037 vs 0.454497 (базовые)
Var(F1): 0.085077 vs 0.087920 (базовые)

Вывод

Агрессивный oversampling V1 сделал распределение классов “красивее”, но ухудшил итоговый Score по сравнению с сырыми данными.

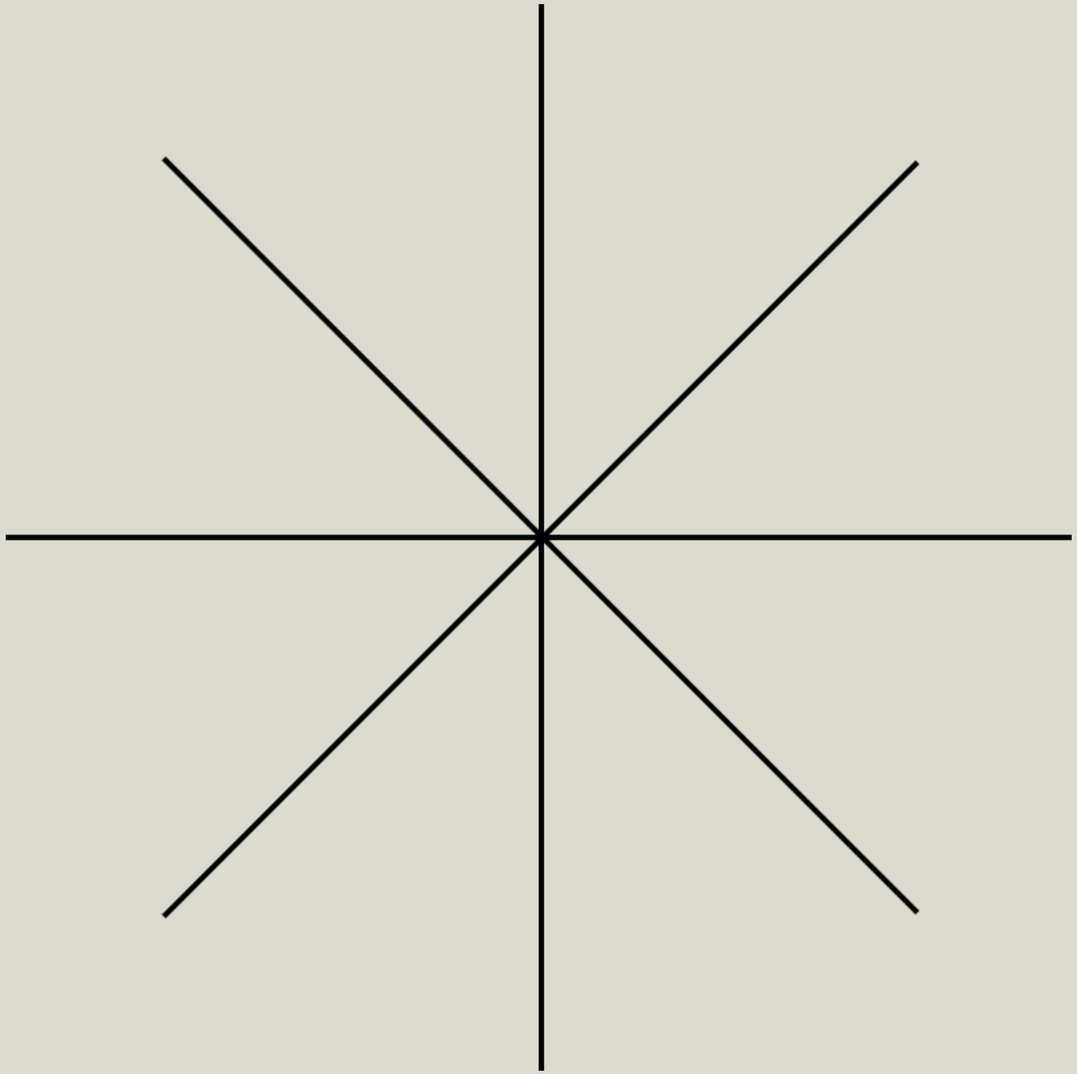

07
Мягкая балансировка хвоста

ИДЕЯ V2

ПОСЛЕ АГРЕССИВНОГО OVERSAMPLING'А МЫ РЕШИЛИ СНИЗИТЬ ВМЕШАТЕЛЬСТВО В РАСПРЕДЕЛЕНИЕ КЛАССОВ.

1

МЯГКАЯ ТЕКСТОВАЯ ПРЕДОБРАБОТКА

- нормализуем переносы строк и табы;
- заменяем «», “”, –, —, ..., неразрывные пробелы на обычные символы;
- схлопываем лишние пробелы, ограничиваем подряд идущие пустые строки;
- не вырезаем содержимое писем и хвосты ЭЦП.

2

МЯГКИЙ OVERSAMPLING ХВОСТА

Для каждого класса:

- если $N \geq 8$ — ничего не делаем;
- если $N < 8$ — дублируем письма до $N = 8$.

То есть меняем только самые редкие классы, остальные оставляем как есть.

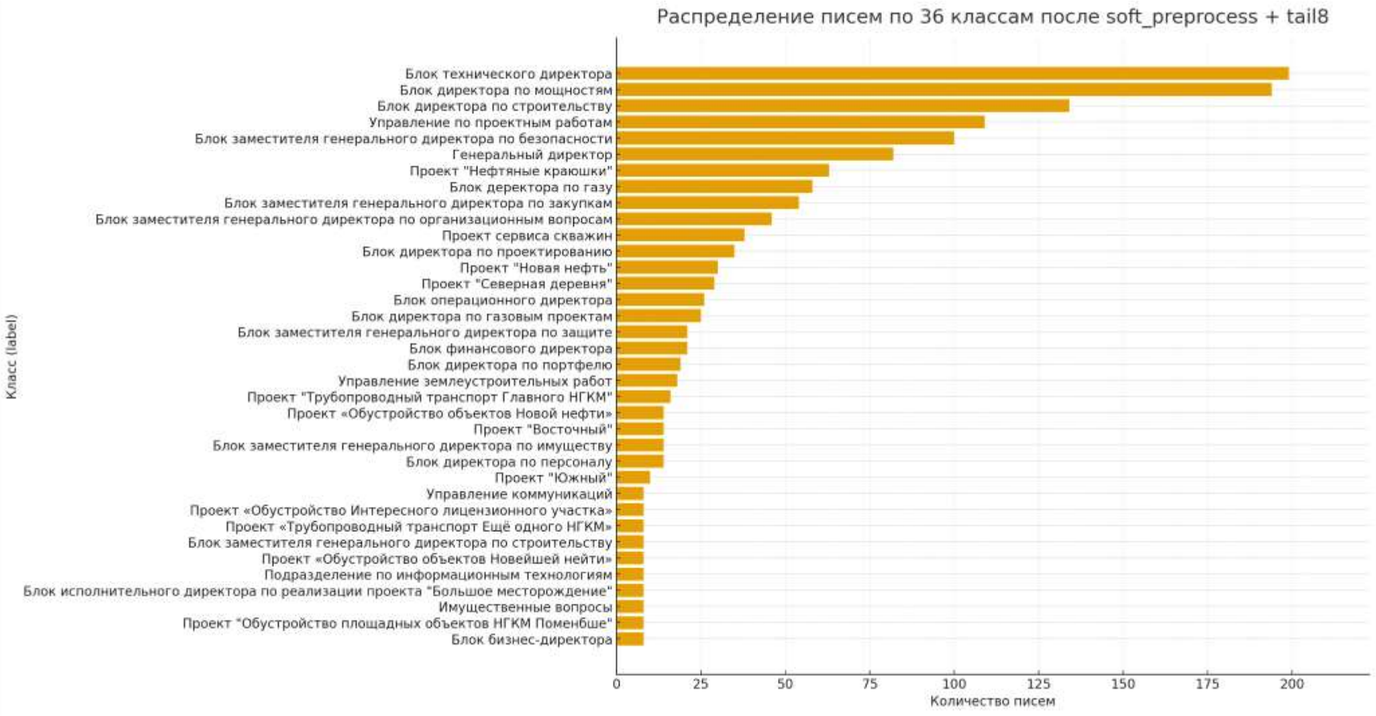

Сводка

1163 писем (рост ≈ +2%);
всё ещё 36 классов;
минимум: 8 писем на класс,
25-й перцентиль: 8,
медиана: 20,
75-й перцентиль: 48,
максимум: 199.

Изменение метрик

Score: 0.423089 vs 0.424846 (базовые)
Macro F1: 0.453530 vs 0.454497 (базовые)
Var(F1): 0.092667 vs 0.087920 (базовые)

Вывод

Мягкий oversampling до 8 даёт качество очень близкое к сырому, и заметно лучше агрессивной версии V1.

08
Методы очистки текста

	Вариант текста	mean	min	25%	50%	75%	max
0	RAW (как в исходном JSON)	3027	49	931	1279	1972	69225
1	soft_preprocess	3018	49	928	1279	1972	69225
2	soft_preprocess + удаление хвоста ЭЦП	2882	49	900	1252	1915	69225
3	soft_preprocess + trim до 4000 символов	1633	49	928	1279	1972	4000

SOFT_PREPROCESS почти не меняет длину писем → безопасная нормализация.

Удаление хвостов ЭЦП чуть укорачивает тексты (MEAN 3027 → 2882).

Обрезка до 4000 резко меняет распределение (MEAN падает до 1633, MAX = 4000).

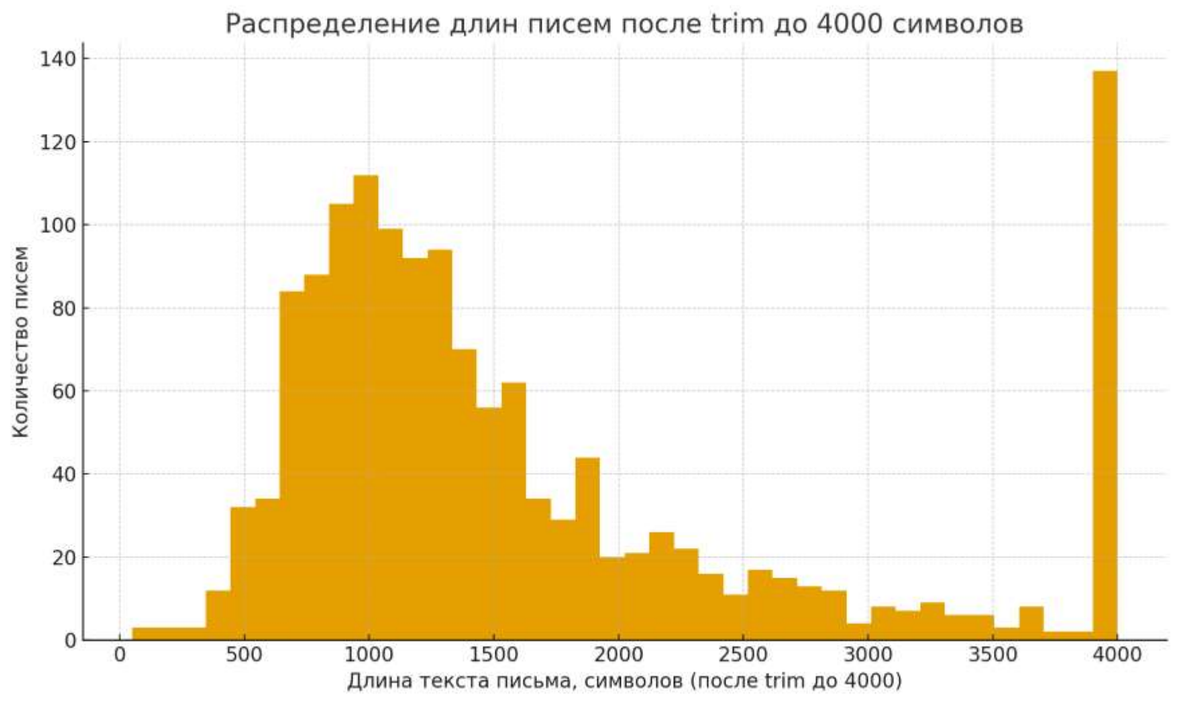

Распределение длин писем после SOFT_PREPROCESS + TRIM до 4000 символов.

Видно большое скопление писем ровно на границе 4000 символов — это явный признак потери части содержимого.

ЭКСПЕРИМЕНТЫ

1

МЯГКАЯ НОРМАЛИЗАЦИЯ

- заменяем “кривые” кавычки, тире, многоточия и неразрывные пробелы на стандартные символы;
- нормализуем переносы строк и табы;
- схлопываем лишние пробелы и слишком длинные блоки пустых строк;
- не удаляем ни заголовки, ни блоки ЭЦП, ни вложения по тексту.

2

УДАЛЕНИЕ ХВОСТОВ ЭЦП

- мы заметили повторяющиеся блоки вида «ДОКУМЕНТ ПОДПИСАН...»;
- реализовали функцию, которая обрезает текст от фразы "ДОКУМЕНТ ПОДПИСАН" до конца;
- на уровне длины писем: средняя длина уменьшилась с 3027 до 2882 символов, немного сдвинулись нижние перцентили.

3

ОБРЕЗКА ДЛИННЫХ ПИСЕМ ДО 4000 СИМВОЛОВ

гипотеза: BERT всё равно ограничен по длине входа, значит, если мы заранее обрежем тексты до 4000 символов, мы:

- уменьшили бы “шум” длинных портянок;
- упростили бы задачу модели.

ИТОГ ЭКСПЕРИМЕНТОВ

ЧТО ПРОИЗОШЛО С ДЛИНАМИ

- среднее: 3027 → 1633 символов;
- минимум/медиана/75% почти не изменились (они и так <4000);
- максимум стал строго 4000.

ЧТО С КАЧЕСТВОМ

- локальный pseudo-score TF-IDF-модели упал примерно до 0.39;
- эксперимент (предобработка + обрезка, без oversampling) показал, что и BERT на тесте работает заметно хуже, чем на не обрезанных текстах.

09
Разметка и генерация данных

ИДЕЯ

МЫ ПРЕДПОЛОЖИЛИ, ЧТО В ДАТАСЕТЕ МОГУТ БЫТЬ ОШИБКИ РАЗМЕТКИ: ПИСЬМО ПОПАЛО “НЕ В ТОТ ОТДЕЛ”. ДЛЯ ИХ ПОИСКА ОБУЧИЛИ BASELINE-МОДЕЛЬ:

- TF-IDF ПО ТЕКСТУ;
- ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ С CLASS_WEIGHT="BALANCED".

ПРОЦЕДУРА И РЕЗУЛЬТАТ

1. Обучаем TF-IDF + логрег на исходном train.
2. Для каждого письма считаем предсказанную вероятность классов.
3. Помечаем письмо как “подозрительное”, если:
   - модель очень уверена (p > 0.9) в каком-то другом классе,
   - он не совпадает с исходным label.
4. Для части таких писем мы сформировали версию датасета, где переприсвоили метки на предсказанные моделью.

Score: 0.406840
Macro F1: 0.435475
Var(F1): 0.081997

Получилось хуже, чем V1. По факту мы подогнали разметку под линейную регрессию, что не подходит для настоящей BERT-модели. Идея была неудачная, мы от нее отказались.

ИДЕЯ

У ХВОСТОВЫХ КЛАССОВ 2–6 ПИСЕМ. ХОТЕЛОСЬ ДАТЬ ИМ БОЛЬШЕ РАЗНООБРАЗИЯ, ПОЭТОМУ МЫ РЕШИЛИ ДОСИНТЕЗИРОВАТЬ ПИСЬМА В ТОМ ЖЕ СТИЛЕ.

ПРОЦЕДУРА И РЕЗУЛЬТАТ

Для каждого редкого класса (n < 10):

- выгружали несколько реальных писем этого класса;
- формировали промпт для LLM (GPT): “Вот примеры писем для подразделения X в обезличенном формате. Сгенерируй ещё N похожих, сохраняя стиль, структуру и анонимизацию ([ORGANIZATION], [PERSON] и т.д.).”;
- добавляли по нескольку сгенерированных писем для каждого класса.

В результате получили датасет, где:

- количество объектов выросло примерно до 1466 писем;
- хвостовые классы получили дополнительные синтетические примеры.

Score: 0.381405

Macro F1: 0.412201

Var(F1): 0.094838

Получилось хуже, чем все предыдущие попытки. Синтетические письма по стилю отличаются от реальной переписки. BERT частично переучивается на “GPT-стиль” и хуже обобщает на настоящие письма. Идея тоже была неудачная, мы от нее отказались.

10
Эволюция датасета и результатов

	Версия	Что мы делали с данными	Размер (N)	Macro F1	Var(F1)	Score
0	RAW	Исходный датасет без обработки	1421	0.454497	0.087920	0.424846
1	V1	Агрессивный oversampling (классы <20 → 30, …	1899	0.446037	0.085077	0.416869
2	V2	soft_preprocess + мягкий oversampling хвост…	1463	0.453530	0.092667	0.423089
3	AutoLbl	Авто-коррекция лейблов по TF-IDF + логрег	1898	0.435475	0.081997	0.406840
4	GPT-tail	Догенерация писем для хвостовых классов (LL…	1466	0.412201	0.094838	0.381405

Агрессивный oversampling (v1)

Делает распределение классов красивым, но ухудшает Score по сравнению с сырой версией.

“Умные” попытки крутить таргеты (AutoLbl, GPT-tail)

Улучшают локальные метрики простых моделей, но сильно портят качество BERT на скрытом тесте.

Мягкий oversampling (v2)

soft_preprocess + лёгкая поддержка хвостовых классов, даёт Score близкий к лучшему сырому, и при этом делает датасет чуть более “здоровым” с точки зрения хвоста.

ФИНАЛЬНОЕ РЕШЕНИЕ

Мы сохраняем исходное распределение классов, используем только мягкую нормализацию текста и минимальный oversampling хвоста до 8 писем.

ЭТО ДАЁТ БАЛАНС МЕЖДУ КАЧЕСТВОМ НА BERT И АДЕКВАТНОСТЬЮ ДАННЫХ.

СПАСИБО ЗА ВНИМАНИЕ!
МЫ ГОТОВЫ ОТВЕТИТЬ НА ВАШИ ВОПРОСЫ!